

Q 梯度引导的在线真机强化学习

让 VLA 模型在真实机械臂环境中边做边学


Learning Procedure | 学习流程

1. Offline | 离线预训练



预训练策略与
Critic 基础

2. Online | 在线自主进化



仅需成功 / 失败标注


核心逻辑: Critic 自主 rollout 产生交互数据 → 价值训练 →
Q 梯度将差一点动作推向更优位置 → 优质经验回馈 VLA 本体

Policy Architecture | 策略架构

Observations
观测数据



Action Proposals
候选动作



多任务 Critic



真实机械臂




回放池
(Replay Buffer)



离线 / 在线复用

建构原则: 共享 VLA + Critic 本体 = 多任务扩展

三大优势



三大效果

插花任务精度

50% → 80%
+30个百分点

推理时延

140 ms → 40 ms
约 3.5× 加速

真机强化耗时

约 10 h → 约 1~2 h
数据成本降低约 80%~90%

离线预训练 → 在线自主进化 · 真机闭环 · 失败可回滚